STAI: Geometric Learning Assignment 3

Matei Bejan, Andrei Manolache, Mihaela Nistor

Table of contents

Notebook 1: Learning Tangent Data

Notebook 2: Fréchet Mean and Tangent PCA



- Am modificat logica de evaluare, iar acum vom cauta hiperparametri cu Cross-Validare pentru fiecare metrica in cazul in care lucram pe varietate, si pentru cazul in care lucram in spatiul Euclidian.
- Am introducs inca doua modele: SVM si Random Forest.
- Obiectivul pentru CV e schimbat in ROC-AUC, care e mai robust la dezechilibrul intre clase.
- Rezultatele sunt mult mai apropriate dupa ce cautam hiperparametri, iar in unele cazuri sunt chiar mai bune decat pe spatiul Euclidian!



- Implementam kernel-ul de la https://ieeexplore.ieee.org/document/6247965.
- Kernelul ne ajuta sa proiectam datele pe varietatea matricelor SPD si sa optimizam modelul pe spatiul tangent, tinand cont de metrica Log-Euclidiana.
- Operatiile ar trebui sa fie echivalente cu folosirea unui kernel liniar impreuna cu proiectia pe spatiul tangent si folosirea metricii LE, dar in practica, SVM-ul ce foloseste kernel-ul implementat are rezultate mai bune.
- O observatie interesanta e faptul ca daca proiectam datele de pe varietate pe spatiul tangent si folosim un kernel rbf care proiecteaza la randul lui datele intr-un spatiu infinit dimensional, rezultatele sunt considerabil mai bune.



SVC			
Metric	CV Score		
Al	0.809%		
LE	0.812%		
Euclidean	0.815%		

Random Forest		
Metric	CV Score	
Al	0.808%	
LE	0.827%	
Euclidean	0.799%	







Figure: Folosim KernelPCA pentru a folosi kernel-ul definit anterior cu metoda PCA. Rezultatele cu KernelPCA, Proiectie, si TangentPCA sunt identice, dupa cum ne-am si asteptat.

- Notebook-ul 2 se concentreaza pe vizualizarea datelor in geomstats, cu precadere a decompozitiei datelor pe hipersfera.
- Am plicat decompozitia TangentPCA cu linear mean din geomstats, pe langa rezultatele deja existente cu Fréchet mean.










Figure: Fréchet and linear mean decompositions in 3D.




Figure: Data distribution in the (Y, Z) space and Fréchet and linear mean superposition.








Figure: Fréchet and linear mean decompositions' projections in the (Y, Z) space.

- Notebook-ul 3 prezinta modul de folosire al algoritmului Kmeans din Geomstats pe 2 clustere de puncte generate pe o hipersfera.
- Desi algoritmul este unul nesupervizat, am folosit label-urile punctelor pentru a compara rezultatele dintre mai multi algoritmi de clusterizare din Geomstats cu cei din Sklearn, mutand punctele in spatiul tangent.


Method	Accuracy
Kmeans Geomstats	92.42%
Kmeans Sklearn	92.42%
KMedoids Geomstats	90.42%
KMedoids Sklearn	90.90%




Agglomerative Hierarchical Clustering Geomstats				
Euclidean	L2	L1	Cosine	
49.5%	49.5%	84.5%	89.0%	

Agglomerative Hierarchical Clustering Sklearn				
Euclidean	L2	L1	Cosine	
83.5%	49.5%	88.0%	87.0%	












Figure: Sklearn K-Means and K-Medoids.






Figure: Agglomerative Hierarchical Clustering Geomstats results: Euclidean, L2, L1, Cosine




Figure: Agglomerative Hierarchical Clustering Sklearn results: Euclidean, L2, L1, Cosine.

